



UNIVERSITÀ DI PISA

PROGETTO PER IL CORSO DI DATA MINING

# **Analisi del Dataset Human Resources Analytics**

*Gianmarco Ricciarelli & Maria Cristina Uccheddu*

# Indice

<b>1</b>	<b>Data Understanding</b>	<b>4</b>
1.1	Data semantics . . . . .	4
1.2	Distribution of the variables and statistics . . . . .	4
1.3	Assessing data quality . . . . .	4
1.4	Variable transformations . . . . .	4
1.5	Pairwise correlations and eventual elimination of redundant variable . .	4
<b>2</b>	<b>Clustering analysis</b>	<b>5</b>
2.1	Clustering Analysis by K-means . . . . .	5
2.1.1	Choice of attributes and distance function . . . . .	5
2.1.2	Identification of the best value of k . . . . .	5
2.1.3	Characterization of the obtained clusters by using both analysis of the k centroids and comparison of the distribution of variables within the clusters and that in the whole dataset . . . . .	5
<b>3</b>	<b>Association Rules</b>	<b>6</b>
<b>4</b>	<b>Classification</b>	<b>7</b>

# **Elenco delle figure**

# Capitolo 1

## Data Understanding

### 1.1 Data semantics

Il progetto viene svolto sul dataset (simulato) **Human Resources Analytics**. Questo dataset contiene le informazioni sui dipendenti di un'azienda fittizia, suddivise in base ai seguenti campi:

**satisfaction\_level** - valutazione *quantitativa* del livello di soddisfazione di ciascun dipendente, ha un valore compreso tra 0 (minimo) e 1 (massimo);

**last\_evaluation** - tempo trascorso, in anni, dall'ultima valutazione delle performance del dipendente;

**number\_project** - numero di progetti completati durante il periodo di lavoro;

**average\_monthly\_hours** - media delle ore di lavoro in un mese;

**time\_spend\_company** - numero di anni trascorsi nell'azienda;

**work\_accident** - esprime con un 1 il coinvolgimento di un dipendente in un incidente sul lavoro, altrimenti viene impostato come 0;

**left** - se il dipendente ha lasciato l'azienda viene impostato come 1, altrimenti come 0;

**promotion\_last\_5years** - se il dipendente è stato promosso negli ultimi 5 anni viene impostato come 1, altrimenti come 0;

**sales** - definisce il dipartimento nel quale il dipendente lavora;

**salary** - esprime il livello (*low, medium, high*), di salario nel quale rientra il dipendente;

### 1.2 Distribution of the variables and statistics

### 1.3 Assessing data quality

### 1.4 Variable transformations

### 1.5 Pairwise correlations and eventual elimination of redundant variable

## **Capitolo 2**

# **Clustering analysis**

### **2.1 Clustering Analysis by K-means**

**2.1.1 Choice of attributes and distance function**

**2.1.2 Identification of the best value of k**

**2.1.3 Characterization of the obtained clusters by using both analysis of the k centroids and comparison of the distribution of variables within the clusters and that in the whole dataset**

## **Capitolo 3**

# **Association Rules**

## **Capitolo 4**

# **Classification**