



UNIVERSITÀ DI PISA

PROGETTO PER IL CORSO DI DATA MINING
A.A. 2017/2018

Analisi del Dataset Human Resources Analytics

Gianmarco Ricciarelli
Maria Cristina Uccheddu
Stefano Carpita

Indice


1	Data Understanding	1
1.1	Obiettivi	1
1.2	Data semantics	1
1.3	Distribution of the variables and statistics	1
1.4	Data quality	3
1.5	Variable transformations	3
1.6	Pairwise correlations and eventual elimination of redundant variable	4
2	Clustering analysis	5
2.1	Clustering Analysis by K-means	5
2.1.1	Choice of attributes and distance function	5
2.1.2	Identification of the best value of k	5
2.1.3	Characterization of the obtained clusters	5
2.2	Hierarchical clustering	7
3	Association Rules	9
4	Classification	10

1 | Data Understanding

1.1 Obiettivi

In questo progetto viene analizzato il dataset (simulato) *Human Resources Analytics* contenente le informazioni sui dipendenti di un'azienda fittizia. Come mostrato in Figura 1.1 su un totale di 14999 dipendenti il 24%, corrispondente a 3571 lavoratori, ha lasciato l'azienda. Gli obiettivi primari dell'analisi sono i seguenti:

- capire i motivi principali per cui i lavoratori hanno lasciato l'azienda;
- predire probabilisticamente se un lavoratore lascerà in futuro l'azienda;
- indicare al management dell'azienda dei provvedimenti da attuare per ridurre il numero di impiegati che la abbandonano.



1.2 Data semantics

In tabella 1.1 sono riportate le variabili relative ai dipendenti dell'azienda e la corrispondente tipologia.

Con la prima variabile, *Satisfaction Level*, viene fornita una valutazione quantitativa del livello di soddisfazione di ciascun dipendente, in un range che va da un valore minimo di 0 ad un massimo di 1. *Last Evaluation* fornisce l'ultima valutazione delle performance del dipendente. *Number Project* riporta il numero di progetti completati da ciascun dipendente durante il periodo di lavoro. *Average Monthly Hours* rappresenta la media delle ore di lavoro in un mese. *Time Spend Company* corrisponde al numero di anni trascorsi dal dipendente all'interno dell'azienda. *Work Accident* esprime con un 1 il coinvolgimento di un dipendente in un incidente sul lavoro, altrimenti viene impostato come 0. *Left* è utilizzata per tener traccia dei dipendenti che hanno lasciato l'azienda, per i quali viene usato il valore 1, mentre per quelli che sono rimasti viene usato il valore 0. *Promotion last 5 Year* esprime con un 1 se il dipendente è stato promosso negli ultimi 5 anni, altrimenti assume il valore 0. *Sales* definisce il dipartimento nel quale il dipendente lavora, e *Salary* esprime il livello (*low*, *medium*, *high*) nel quale rientra il salario del dipendente. Le descrizioni delle variabili sono state estrapolate dai metadati forniti assieme al Dataset sulla pagina di Kaggle ¹ nella quale il Dataset è contenuto. La scelta di catalogare le colonne *Work Accident*, *Left* e *Promotion Last 5 Years* come variabili di tipo categorico verrà opportunamente motivata nelle sezioni successive.

Figura 1.1: Numero di lavoratori

Field	Type
satisfaction_level	continuous
last_evaluation	continuous
number_project	discrete
average_monthly_hours	discrete
time_spend_company	discrete
salary	ordinal
work_accident	categorical
promotion_last_5years	categorical
sales	categorical
left	categorical

Tabella 1.1: Variabili presenti nel Dataset e rispettivi tipi.








1.3 Distribution of the variables and statistics

In questo paragrafo vengono presentati i grafici relativi alla distribuzione dei valori assunti dalle variabili descritte nella sezione precedente. Per dare una migliore interpretazione a questi abbiamo deciso di sostenere un'analisi accurata che contraddistingue i dipendenti che lavorano nell'azienda, rappresentati dal colore blu, e quelli che invece la hanno lasciata, rappresentati dal colore rosso. Come si può constatare dal grafico in Figura 1.1 in un totale di 14999 dipendenti analizzati: 3571 di questi hanno lasciato l'azienda (quasi il 24% del totale), mentre i restanti 11428 dipendenti (quasi il 76%) sono rimasti nella azienda. Prima di tutto vogliamo studiare la distribuzione dei dipendenti rispetto alle variabili categoriche. La distribuzione mostrata in Figura 1.2a indica la distribuzione degli impiegati nei vari settori: (parte mancante).

Nel grafico in Figura 1.2b si studia il rapporto tra i dipendenti e la presenza o meno di un infortunio durante il periodo di lavoro all'interno dell'azienda e si è riscontrato che soltanto 169 impiegati tra i 3571 che se ne sono andati hanno avuto un incidente sul lavoro, mentre gli impiegati ancora all'interno dell'azienda ad aver subito un incidente sono 2000 su 11428.

Nel grafico in Figura 1.2c invece rapportiamo ciascun dipendente al fatto che questo sia stato promosso negli ultimi 5 anni oppure no, possiamo ricavare una informazione importante, la totalità degli impiegati che hanno lasciato l'azienda non ha avuto una promozione negli ultimi 5 anni. Soltanto 19 impiegati su 11428 di quelli rimasti sono stati promossi. Una volta studiate le distribuzioni categoriche continuiamo l'analisi con gli altri attributi, per renderle più esplicative abbiamo affiancato a ciascun grafico la tabella che lo descrive in modo accurato e in modo che fosse autoesplicativo.

¹<https://www.kaggle.com/>

(a) Distribuzione relativa alla variabile *Sales*(b) Distribuzione relativa alla variabile *Work Accident*(c) Distribuzione relativa alla variabile *Promotion Last 5 Years*(d) Distribuzione relativa alla variabile *Salary*.(e) Distribuzione relativa alla variabile *Average Montly Hours*(f) Distribuzione relativa alla variabile *Satisfaction Level*(g) Distribuzione relativa alla variabile *Last Evaluation*(h) Distribuzione relativa alla variabile *Number Project*

Dipendente	Low	Medium	High
InAzienda	5144 (circa 45.02%)	5129 (circa il 44.88%)	1155 (circa il 10.1%)
OutAzienda	2172 (circa 60.8%)	1317 (circa il 36.9%)	82 (circa il 2.3%)

(a) Distribuzione salario per dipendente.

Dipendente	media	dev. std.	min,max
InAzienda	199.06	45.68	96 , 287
OutAzienda	207.42	61.20	126 , 310

Dipendente	media	dev. std.	min,max
InAzienda	0.67	0.22	0.12 , 1.0
OutAzienda	0.44	0.26	0.09 , 0.92

(b) Il tempo medio di ore di lavoro al mese per dipendente.

(c) Livello di soddisfazione per il dipendente.

Dipendente	media	dev. std.	min,max
InAzienda	0.71	0.16	0.36 , 1.0
OutAzienda	0.71	0.19	0.45 , 1.0

(d) Livello di soddisfazione per il dipendente relativo all'ultima valutazione.

Abbiamo rapportato in primis i dipendenti con il proprio salario: possiamo osservare la distribuzione della variabile in Figura 1.2d e le relative percentuali in Tabella 1.2a. Le percentuali che vengono indicate nella tabella non sono in base alla totalità dei dipendenti ma riguardano solo il tipo di dipendente definito dalla riga di appartenenza.

Proseguendo poi con il rapporto tra dipendenti ancora in azienda e non, e il numero delle ore di lavoro in media, possiamo osservare la distribuzione della variabile in Figura 1.2e, e le relative percentuali riportate in Tabella 1.2b.

A questo punto è giusto analizzare il livello di soddisfazione dei dipendenti, del quale possiamo osservare la distribuzione in Figura 1.2f e le relative percentuali in Tabella 1.2c.

Possiamo rapportare rispetto alla precedente valutazione del livello di soddisfazione (cambiare valori della tabella) osservan

1.4 Data quality

- Missing values

- Outliers

L'individuazione dei possibili outliers di una variabile numerica consiste nel verificare se siano presenti dei valori estremi rispetto alla distribuzione dei dati osservati. I test comunemente utilizzati, come il test di Grubb o il criterio di Chauvenet, sono basati sull'assunzione di una distribuzione di probabilità gaussiana, che non si osserva per le variabili numeriche del dataset analizzato (spiegare in distribution of the variables). Un metodo robusto e di immediata applicazione è quello di osservare il boxplot dei dati, identificando come candidati outliers i valori che si trovano al di fuori dei whiskers, ovvero valori x della variabile osservata per cui $|x - \tilde{x}| > 2 IQR(x)$, dove \tilde{x} è la mediana ed $IQR(x)$ lo scarto interquartile.




Figura 1.3: Boxplots per le variabili numeriche

1.5 Variable transformations

Analizzando il significato delle variabili presenti nel dataset, abbiamo deciso di rappresentare *Work Accident* e *Left* utilizzando il tipo categorico piuttosto che quello discreto. Questa scelta è stata motivata dall'analisi semantica delle due variabili, le quali forniscono una risposta del tipo "Sì o No" alle domande relative agli incidenti sul lavoro e all'abbandono o meno dell'azienda da parte dei dipendenti.

1.6 Pairwise correlations and eventual elimination of redundant variable

In questa sezione abbiamo studiato la correlazione ovvero la relazione lineare tra i vari attributi continuous o discreti. Dalla matrice riportata in Figura 1.4 possiamo rilevare se ci sia una correlazione positiva, nulla o negativa. Sia per quanto riguarda la correlazione positiva sia per quella negativa si caratterizzano in settori: con valori da 0 a 0.3 correlato debolmente, da 0.3 a 0.7 moderatamente o maggiore di 0.7 fortemente (rispettivamente per la negativa i segni saranno negativi). Da questo possiamo definire che ad avere una correlazione debole è la variabile `time_spend_company` con `left`, `last_evaluation`, `number_project` e `average_monthly_hours`. Queste ultime, ad eccezione di `left`, invece sono correlate fra loro in modo moderato con un valore massimo di 0.42 tra `average_monthly_hours` e `number_project`. Il valore 1 indica la correlazione con se stesso che infatti è massima. Dal punto di vista della correlazione negativa, abbiamo debolmente correlati `left` con `work_accident` e `satisfaction_level` con `number_project` e `time_spend_company`. Abbiamo invece una correlazione negativa moderata tra `left` e `satisfaction_level` di valore -0.39 .



Figura 1.4: Correlation Matrix delle variabili presenti nel Dataset.

2 | Clustering analysis

In questo secondo capitolo del report, ci occupiamo di rilevare, attraverso l'applicazione degli algoritmi *K-means*, *Hierarchical* e *DbSCAN*, i gruppi di dipendenti con caratteristiche comuni all'interno del data set. La nostra analisi è stata inizialmente svolta sul data set completo, utilizzando però solo alcune variabili tra quelle a disposizione, come verrà spiegato nella sezione 2.1.1. Per questa analisi globale vengono inoltre fornite alcune statistiche, per meglio integrare le informazioni ottenute dal clustering. Come già specificato nella Sezione 1.5, i valori delle variabili discrete sono stati normalizzati in un intervallo compreso tra 0 e 1, al fine di rendere più agevole il confronto in fase di clustering. Infine, come ulteriori casi di studio, sono riportate anche le analisi relative alla sola porzione del data set contenente gli impiegati che hanno lasciato l'azienda e a quella invece contenente gli impiegati ancora al suo interno.

2.1 Clustering Analysis by K-means

2.1.1 Choice of attributes and distance function

Le variabili sulle quali abbiamo deciso di applicare l'analisi tramite K-means sono un sottoinsieme di quelle a disposizione nel data set, in particolare, sono le variabili di tipo continuo *Satisfaction Level* e *Latest Evaluation*, e le variabili di tipo discreto *Number Project*, *Average Monthly Hours* e *Time Spent Company*. Sono state escluse le variabili binarie. Vista la natura delle variabili utilizzate nell'applicazione dell'algoritmo, la distance function da noi utilizzata per quantificare la distanza tra due data objects è la *distanza Euclidea*, rappresentata dalla nota formula

$$dist(p, q) = \sqrt{\sum_{i=0}^k (q_i - p_i)^2} ,$$

dove con q_i e p_i vengono rappresentati li i -esimi attributi dei data objects p e q .

2.1.2 Identification of the best value of k

Al fine di identificare il miglior numero k di clusters da utilizzare, abbiamo tenuto conto dell'*Error Sum of Squares* (SSE), ossia della somma, elevata al quadrato, della distanza tra ogni singolo data object e il centroide più vicino, ottenuta mediante la formula

$$SSE = \sum_{i=1}^K \sum_{x \in C_i} dist(c_i, x)^2 ,$$

dove $dist$ rappresenta la distanza Euclidea tra il centroide c_i ed il data object x . A partire da un valore iniziale di k pari a 2 fino ad un valore massimo di 50 abbiamo calcolato l'SSE risultante dall'applicazione dell'algoritmo come possiamo osservare in Figura ??, e abbiamo infine deciso per un valore di k pari a 4 per l'applicazione di K-means sul data set totale. Tale valore è stato poi confermato come il più elevato tra quelli osservati tramite lo studio del *Silhouette score*.

2.1.3 Characterization of the obtained clusters

In quest'ultima sezione relativa all'algoritmo K-means descriviamo i clusters emersi durante l'analisi. Utilizzando i parametri descritti nelle sezioni precedenti, abbiamo ottenuto i clusters raffigurati in Figura 2.1, dove possiamo osservare la densità di popolazione per ognuno dei cluster ottenuti. In Tabella 2.1 abbiamo riportato i dati caratteristici di ognuno dei cluster scoperti. Il primo cluster emerso, Cluster 0, è quello con una densità di popolazione minore, e contraddistingue gli impiegati con un alto score nelle variabili *Average Monthly Hours*, *Last Evaluation*, *Number Project* e *Time Spent Company*. Possiamo pensare a un tale cluster come a un gruppo di impiegati molto produttivi, ma con un livello di soddisfazione non troppo elevato. Il secondo Cluster, Cluster 1, presenta un gruppo di impiegati con un valore molto basso sia in *Time Spent Company* che in *Average Monthly Hour*, e valori poco sopra 0.55 nelle altre variabili. Il Cluster 2 è probabilmente quello più allarmante, dal momento che è composto da impiegati con un bassissimo score nella variabile *Satisfaction Level*, e uno score elevato sia in *Last Evaluation* che in *Number Project*. Possiamo pensare a un gruppo di impiegati che hanno mantenuto un livello di produttività alto dovuto ad elevati carichi di lavoro, fattore che ha comportato il calo vertiginoso del livello di soddisfazione. Il fatto che tale cluster sia anche quello più densamente popolato è un ulteriore motivo di interesse verso questo gruppo di impiegati. L'ultimo cluster, il 3 presenta anch'esso un basso score nella variabile *Satisfaction Level*, mentre vale il contrario per le variabili *Last Evaluation* e *Number Project*. Lo score di circa 0.41 nella variabile *Time Spent Company* fa pensare ad un gruppo di impiegati molto produttivi, i quali da non molto lavorano all'interno dell'azienda, e a rischio dal momento che questo alto tasso di produttività sta probabilmente compromettendo il loro livello di soddisfazione.

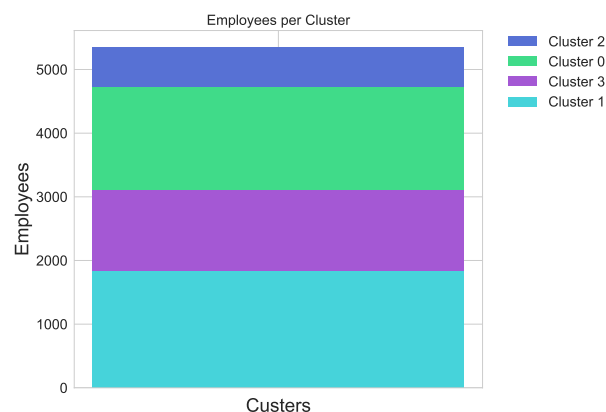


Figura 2.1: Distribuzione del numero di impiegati per ognuno dei cluster scoperti durante l'analisi, in ordine decrescente per densità di popolazione.

Average_Montly_Hours					
Cluster	count	mean	std	min	max
0	1494.0	0.733762	0.204831	0.02	1.00
1	2987.0	0.251463	0.116789	0.00	0.88
2	6784.0	0.519805	0.194971	0.01	1.00
3	2452.0	0.542761	0.215429	0.00	0.99

(a)

Last_Evaluation					
Cluster	count	mean	std	min	max
0	1494.0	0.811693	0.138791	0.37	1.0
1	2987.0	0.556739	0.114149	0.36	1.0
2	6784.0	0.737535	0.152870	0.36	1.0
3	2452.0	0.782822	0.168248	0.36	1.0

(b)

Number_Project					
Cluster	count	mean	std	min	max
0	1494.0	0.811693	0.138791	0.37	1.0
1	2987.0	0.556739	0.114149	0.36	1.0
2	6784.0	0.737535	0.152870	0.36	1.0
3	2452.0	0.782822	0.168248	0.36	1.0

(c)

Satisfaction_Level					
Cluster	count	mean	std	min	max
0	1494.0	0.633199	0.482093	0.0	1.0
1	2987.0	0.520589	0.499660	0.0	1.0
2	6784.0	0.012529	0.111240	0.0	1.0
3	2452.0	0.316476	0.465196	0.0	1.0

(d)

Time_Spend_Company					
Cluster	count	mean	std	min	max
0	1494.0	0.753414	0.179673	0.0	1.0
1	2987.0	0.091530	0.141061	0.0	0.8
2	6784.0	0.364092	0.169420	0.0	1.0
3	2452.0	0.417129	0.193405	0.0	0.8

(e)

Tabella 2.1: Statistica descrittiva relativa alle variabili utilizzate nell'applicazione dell'algoritmo K-means in fase di clustering.

2.2 Hierarchical clustering




Figura 2.2: Dendrogramma per method X e metrica Y




Figura 2.3: Confronto tra diversi metodi




Figura 2.4: Confronto tra silhouette medie, per due clusters




Figura 2.5: Confronto tra silhouette medie, per due clusters

3 | Association Rules

4 | Classification